

Chatbot RAG para Normas Estruturais ABNT

Recuperação Híbrida: Dense + Sparse + RRF

Eduardo Braga · Israel Magalhães · Marcelo Carvalho

Processamento de Linguagem Natural — IFG Pós-IA

O Problema

Pergunta: "Qual a carga accidental para garagem de veículos leves?"

- LLMs generativos alucinam ou ficam desatualizados
- Normas ABNT são periodicamente revisadas
- Valores numéricos errados = **consequências graves na engenharia**

Solução: RAG — Retrieval-Augmented Generation

A resposta sempre vem ancorada em um trecho **real e rastreável** da norma.

Corpus: Normas ABNT


Norma	Título	Edição	Seções
NBR 6120	Cargas para cálculo de estruturas	2019 (2ª ed.)	124
NBR 6123	Forças devidas ao vento em edificações	2023	166

Total: 290 seções · ~626 mil caracteres


NBR 6118 (concreto) foi removida: PDF com encoding corrompido geraria chunks de baixa qualidade e potencial desinformação.

Arquitetura do Pipeline

Pergunta do usuário



top-k chunks



LLM (Groq llama-3.3-70b)



Resposta com citação [NBR6120, §2.2]

Chunking: 1 seção = 1 chunk

Processo:

1. PDF → Markdown via **Docling** (preserva tabelas, listas, headings)
2. Markdown → split por `##` (heading nível 2)
3. Frontmatter YAML automático por chunk

Metadados por chunk:

`chunk_id` · `doc_id` · `secao` · `summary` · `texto` · `n_chars`

Decisões de design:

- **Zero overlap** — seções são unidades semânticas completas
- Tabelas extensas divididas em continuação (`tabela_10_conclusão`)
- Rastreabilidade total: toda resposta tem `chunk_id` de origem

Retriever Dense: BERTimbau + FAISS

Embeddings:

- Modelo: **BERTimbau** (BERT pré-treinado em português)
- Dimensão: 768 · Sem GPU · Sem API externa

Índice:

- FAISS IndexFlatIP — busca exata por similaridade de cosseno
- 290 chunks → busca exata é trivial computacionalmente

Captura **semântica e paráfrases**, mas falha em termos técnicos muito específicos não vistos no pré-treino
(kN/m^2 , § 2.2.1.6)

Retriever Esparso: BM25

- Algoritmo clássico de relevância léxica (TF-IDF com normalização por comprimento)
- Tokenização por **regex alfanumérico** — preserva números e unidades como tokens

Por que BM25?

Consulta	Dense	BM25
"carga accidental em escritório"	✓ semântica	✓ léxico
"3 kN/m² garagem veículos leves"	✗ não viu no treino	✓ match exato
§ 4.2.1.6	✗	✓ token exato

Retrieval Híbrido com RRF

Reciprocal Rank Fusion — funde os dois rankings sem parâmetros de tuning:

$$\text{score}_{RRF}(d) = \sum_{r \in \{dense, sparse\}} \frac{1}{60 + \text{rank}_r(d)}$$

Processo:

1. Cada retriever recupera `k × 3` candidatos (pool ampliado)
2. Fusão via RRF
3. Deduplicação por `chunk_id` — cada chunk conta uma vez
4. Retorna top-k da fusão

O `60` é a constante padrão da literatura — balanceia contribuições de ranks altos e baixos.

Avaliação: Recall@k

Golden set: 21 perguntas (17 factuais · 3 multi-trecho · 1 fora do corpus)

k	Dense	Sparse	Hybrid
3	0,05	0,75	0,45
5	0,05	0,80	0,55
10	0,20	0,85	0,90

Dense — recall muito baixo: títulos técnicos específicos não representados pelo BERTimbau

Sparse — domina em k pequeno: correspondência léxica excelente neste corpus

Hybrid — melhor em k=10: **0,90**, supera ambos os modos individuais

Exemplo Concreto

Pergunta: "Qual a carga accidental para garagem de veículos leves?"

Modo	Resultado
Dense	Não encontrou chunk relevante
Sparse	"Carga uniformemente distribuída: 3 kN/m² · Carga concentrada: 12 kN" — NBR6120, §correto
Hybrid@10	Acertou também (junto com outros chunks relevantes)

O BM25 casou exatamente `garagem` + `veículos leves` com o chunk da NBR 6120.

Teste de recusa (Q21): "Qual o preço do m³ de concreto?" → sistema recusou corretamente: *"Esta informação não está presente no corpus."*

Trade-offs e Latência

Modo	Ponto forte	Limitação	Latência
Dense	Paráfrases, sinônimos	Termos técnicos novos	5–20 ms
Sparse	Valores, referências exatas	Sem semântica	< 1 ms
Hybrid	Robustez geral	Leve overhead	5–20 ms

Recomendação: Hybrid para produção — captura ambos os casos e em $k=10$ supera os modos individuais.

Interface Gradio

- Usuário digita pergunta, escolhe modo (`dense` / `sparse` / `hybrid`) e define k
- Exibe resposta com trechos recuperados, `chunk_id` e score
- `demo.launch(share=True)` gera URL pública no Colab

Conclusão

O que construímos:

- Pipeline RAG funcional com 290 seções normativas
- 3 modos de retrieval com avaliação quantitativa (Recall@k)
- Comportamento de recusa para perguntas fora do corpus

Principal aprendizado:

Para documentos técnicos com terminologia precisa e valores numéricos, BM25 superou embeddings com BERTimbal neste caso. O híbrido com RRF foi a escolha mais robusta testada.

Limitações: corpus restrito · fórmulas não decodificadas pelo Docling

Próximos passos que pensamos experimentar: incluir NBR 6118 · subdividir seções longas