

Relatório: Desenvolvimento de Chatbot RAG para Normas Estruturais ABNT

Grupo: Eduardo Braga, Israel Magalhães e Marcelo Carvalho
Disciplina: Processamento de Linguagem Natural
Trilha escolhida: A - Recuperação Híbrida (*Sparse + Dense*)
Curso: Inteligência Artificial Aplicada - Instituto Federal de Goiás Câmpus Goiânia

1. Domínio e Corpus

Domínio

O sistema foi desenvolvido para auxiliar engenheiros, projetistas e estudantes na consulta a **normas técnicas brasileiras de engenharia estrutural**. O corpus é fechado e composto por documentos normativos da ABNT, documentos de alta precisão terminológica e com valores numéricos críticos, onde respostas incorretas podem ter consequências práticas graves.

O domínio justifica o uso de RAG em detrimento de um LLM direto: normas são atualizadas periodicamente, contêm tabelas e fórmulas específicas, e exigem rastreabilidade das fontes (citações normativas).

Corpus

Norma	Título	Edição	Seções
NBR 6120	Cargas para o cálculo de estruturas de edificações	2019 (2ª edição)	124
NBR 6123	Forças devidas ao vento em edificações	2023	166

Total: 290 seções · ~626 mil caracteres

Metadados por documento:

Campo	Descrição
doc_id	NBR6120 ou NBR6123

Campo	Descrição
titulo	Título completo da norma
fonte	ABNT
edicao	Edição/ano da norma

Justificativa da escolha: A NBR 6120 cobre cargas permanentes e acidentais em edificações, enquanto a NBR 6123 cobre forças de vento. Juntas, formam a base das ações externas consideradas no dimensionamento estrutural brasileiro, domínio de alta relevância prática.

A NBR 6118 (projeto de estruturas de concreto) foi inicialmente incluída mas removida do corpus: o PDF disponível apresenta codificação de caracteres corrompida em trechos significativos (fontes sem suporte Unicode), o que geraria *chunks* de baixa qualidade e potencial desinformação.

2. Segmentação (*Chunking*) — Decisões e Justificativas

Estratégia: cada seção normativa corresponde a um *chunk*

Cada *chunk* corresponde a uma **seção semântica autocontida** da norma (subseção, tabela ou grupo de parágrafos relacionados). Essa estratégia respeita a organização hierárquica dos documentos normativos, evitando cortes arbitrários no meio de definições ou requisitos.

Processo de geração:

1. **PDF** → **Markdown** via [Docling](#): preserva a estrutura de cabeçalhos, tabelas e listas.
2. **Markdown** → **seções** via `scripts/split_sections_auto.py`: divide nos cabeçalhos `##` (nível 2), garantindo que cada *chunk* contenha um conceito ou conjunto de regras coeso.

Metadados por *chunk*:

Campo	Descrição
chunk_id	NBR6120#07_tabela2_cargas_verticais (doc_id + radical do nome do arquivo)
doc_id	NBR6120 ou NBR6123

Campo	Descrição
titulo	Título completo do documento
fonte	ABNT
edicao	Edição da norma
secao	Título da seção (extraído do <i>frontmatter</i> YAML)
summary	Resumo gerado automaticamente da seção
texto	Conteúdo puro (para <i>embedding</i>)
texto_md	Conteúdo com <i>frontmatter</i> (para exibição)
n_chars	Tamanho em caracteres

Tamanho dos *chunks*:

Estatística	NBR 6120	NBR 6123
Mínimo	~130 caracteres	~6 caracteres
Máximo	~3.600 caracteres	~65.000 caracteres
Mediana	~500 caracteres	~500 caracteres

Seções muito pequenas (< 20 caracteres, ex.: cabeçalhos isolados como "3.1") foram mantidas no índice, mas raramente são retornadas como *top-k* relevante e não prejudicaram a qualidade da recuperação.

Decisões sobre tabelas: Tabelas muito extensas (ex.: Tabela 1 de pesos específicos, Tabela 10 de cargas variáveis) são divididas em seções de continuação pelo *auto-split* (*tabela_10_continuacao*, *tabela_10_conclusao*). Isso as torna recuperáveis de forma independente sem diluir o conteúdo narrativo do *chunk* principal.

Sobreposição (*overlap*): Nenhuma. A estrutura normativa já é hierarquicamente organizada, seções são unidades semânticas completas que não requerem sobreposição para manter coerência.

3. *Baseline* RAG

Retriever denso

Para o *retriever* denso do *baseline*, utilizamos o BERTimbau, um modelo BERT pré-treinado em português brasileiro.

Modelo: `neuralmind/bert-base-portuguese-cased` (BERTimbau, dimensão 768)

- Pré-treinado em português, adequado ao vocabulário técnico da ABNT
- Não requer GPU para inferência (CPU viável no Colab)
- Sem dependência de API externa para a etapa de recuperação

Índice: FAISS `IndexFlatIP` com vetores L2-normalizados

- Busca exata por cosseno (sem aproximação)
- Com 290 *chunks*, busca exata é computacionalmente trivial

Configuração: $k = 3, 5$ ou 10 (configurável na interface Gradio)

Prompt e *grounding*

O sistema utiliza um *template* de *prompt* com regras de *grounding* (`src/prompts.py`):

REGRAS OBRIGATÓRIAS:

1. Responda APENAS com base nos trechos normativos fornecidos.
2. Cite as fontes usando o formato [NBRxxxx, Seção Y.Y].
3. Se a informação NÃO estiver nos trechos: "Não encontrei informação suficiente nas normas consultadas para responder esta pergunta."
4. NÃO invente, extrapole ou use conhecimento externo às normas.

Citações

Cada resposta inclui referências no formato [`NBR6120`, `Seção 2.2.1`]. A interface Gradio mostra os trechos recuperados com `chunk_id`, pontuação de relevância e texto completo.

Recusa adequada

O *prompt* instrui o LLM a recusar com frase canônica quando:

- A informação não está nos trechos recuperados
- A pergunta é sobre tema não normativo (preços, marcas comerciais etc.)

LLM de geração

Provedor padrão: **Groq** (llama-3.3-70b-versatile). Alternativa: Google Gemini ou NVIDIA NIM (compatível com API OpenAI).

4. Trilha A — Recuperação Híbrida

Motivação

O *retriever* denso (BERTimbau) captura semântica, mas pode falhar em termos muito específicos não vistos no pré-treino: valores numéricos (kN/m^2), nomes de seções (2.2.1.6), ou termos técnicos raros. O BM25 captura termos exatos, mas ignora sinônimos e paráfrases. A fusão híbrida combina as vantagens de ambos.

Implementação

O módulo `src/hybrid_search.py` implementa dois *retrievers* adicionais ao denso:

SparseRetriever (BM25):

- Tokenizador: *regex* alfanumérico, caixa baixa, com *stemming* PT-BR
- Modelo: `BM25Okapi (rank-bm25)`
- Pontuação: TF-IDF com normalização pelo comprimento do documento

HybridRetriever (BM25 + FAISS + RRF):

- Recupera $\min(k \times 3, n_chunks)$ candidatos de cada *retriever*
- Funde via **Reciprocal Rank Fusion**: $score(chunk) = \sum 1 / (60 + rank)$
- Deduplica por `chunk_id` antes da fusão (cada *chunk* conta uma vez por *retriever*)
- Parâmetro $k_RRF = 60$ (valor padrão da literatura)

Parâmetros

Parâmetro	Valor	Justificativa
<code>k_RRF</code>	60	Constante padrão RRF; equilibra contribuições de <i>retrievers</i> com <i>rankings</i> distintos
Candidatos por <i>retriever</i>	$k \times 3$	Amplia o conjunto antes da fusão, reduzindo o risco de perder o <i>chunk</i> correto

Parâmetro	Valor	Justificativa
Tokenização	<i>regex</i> <code>\W+</code>	Preserva números e unidades (<i>kN</i> , <i>m²</i> , <i>1</i> , <i>5</i>) como <i>tokens</i> relevantes

Análise de compromissos

Os resultados comparativos de Recall@k são apresentados na Seção 5.2. A seguir, discutimos os principais compromissos observados.

Denso apresentou *recall* muito baixo (0,05–0,20). Após a reorganização das seções da NBR 6120 para a edição 2019 (124 *chunks* com títulos técnicos longos), o BERTimbau não representa bem os novos *chunk_ids* semanticamente. O único acerto consistente foi Q11 (velocidade básica V0), onde a consulta contém os mesmos termos do *chunk*.

Esparso (BM25) dominou neste corpus: *recall* 0,75–0,85. A correspondência lexical exata captura termos técnicos normativos (ex.: "cargas variáveis", "garagem", "vento básico", "fator S2") que o denso não consegue mapear semanticamente.

Híbrido combina os dois: em k=10 atinge 0,90, o melhor resultado geral. Para k pequeno (3–5), o BM25 sozinho já é superior ao híbrido, pois o denso "contamina" o *ranking* com *chunks* irrelevantes via RRF.

Latência:

Modo	Tempo típico de recuperação	Gargalo
Esparso	< 1 ms	—
Denso	5–20 ms	Vetorização da consulta (BERTimbau)
Híbrido	5–20 ms	Dominado pela vetorização do denso

5. Avaliação

5.1 Golden Set

O conjunto de avaliação é composto por 21 perguntas cobrindo os dois documentos do corpus:

Categoria	Quantidade	Descrição
<code>factual_direta</code>	17	Pergunta com resposta direta em uma seção
<code>multi_trecho</code>	3	Requer combinar 2–4 seções para responder
<code>fora_do_corpus</code>	1	Testa recusa (pergunta sobre preço de concreto)

Distribuição por norma:

- NBR 6120: 10 perguntas (cargas permanentes, acidentais, tabelas de pesos)
- NBR 6123: 10 perguntas (velocidade do vento, fatores S1/S2/S3, pressão dinâmica, análise dinâmica)
- Fora do corpus: 1 pergunta (teste de recusa)

5.2 Recall@k

Executado via `src/evaluator.py` com o índice reconstruído sobre as 290 seções (NBR 6120:2019 + NBR 6123:2023). Das 21 perguntas, 20 são avaliáveis (1 `fora_do_corpus` excluída). Modo denso = BERTimbau + FAISS. Arquivos de detalhe em `index/eval_details.csv`.

k	Denso (<i>baseline</i>)	Esparso (BM25)	Híbrido (RRF)
3	0,05 (1/20)	0,75 (15/20)	0,45 (9/20)
5	0,05 (1/20)	0,80 (16/20)	0,55 (11/20)
10	0,20 (4/20)	0,85 (17/20)	0,90 (18/20)

Arquivos gerados: `index/recall_at_k_all.json`, `index/eval_comparative.csv`.

Perguntas com acerto no modo denso (k=10): Q3 (peso próprio), Q11 (velocidade V0), Q12 (pressão dinâmica), Q20 (análise dinâmica).

Interpretação: O BERTimbau apresenta baixo *recall* nas seções da NBR 6120:2019 porque os `chunk_ids` têm títulos técnicos muito específicos que o modelo não representa bem semanticamente. O BM25 supera o denso em todas as configurações de k neste corpus. O híbrido atinge o melhor resultado global em k=10 (0,90), evidenciando o valor da fusão para *pools* maiores de candidatos.

5.3 Rubrica Qualitativa

A avaliação qualitativa foi realizada sobre 17 perguntas do *golden set* nos três modos de recuperação (denso / esparso / híbrido), com $k=5$ e *pipeline baseline* usando Groq llama-4-scout-17b como LLM de geração. As questões Q17–Q20 não foram incluídas nesta rubrica por limitações de tempo; os resultados de Recall@k dessas questões constam na Seção 5.2.

Arquivo de detalhamento completo: [data/eval/rubrica_detalhada.md](#) contém as respostas integrais dos 3 modos e tabela de preenchimento por questão.

Automação: a coluna *Faithfulness* foi calculada via **RAGAS** (Groq llama-4-scout como LLM-judge). Essa métrica mede o grau em que as afirmações da resposta têm suporte nos trechos recuperados (escala 0–1). Pontuações completas para os 3 modos em [data/eval/ragas_scores.json](#).

Limitação conhecida do RAGAS para recusas: quando o *pipeline* responde "Não encontrei informação suficiente", o RAGAS atribui *Faithfulness* ≈ 0 (a expressão de recusa não aparece literalmente nos *chunks*). Isso **não indica alucinação**, indica apenas que a recusa é uma decisão do LLM, não uma inferência extraída dos trechos.

Critérios

Critério	Opções	Pergunta-guia	Preenchimento
<i>Groundedness</i>	S / N	A resposta está suportada pelos trechos?	Automático (RAGAS)
Correção	S / P / N	Está factualmente correta conforme a norma?	Manual (Marcelo)
Citações	S / N	Cita trechos adequados e coerentes?	Automático (RAGAS)
Alucinação	S / N	Inventou algo fora do corpus?	Automático (RAGAS)
Recusa	S / N / N/A	Quando não havia evidência, recusou corretamente?	Manual (Marcelo)

As colunas **Correção** (S = correta / P = parcial / N = incorreta) e **Recusa** (S = recusa correta / N = deveria ter recusado / N/A = respondeu) foram preenchidas manualmente por Marcelo Carvalho, engenheiro civil do grupo, com base em sua experiência profissional e

consulta direta às normas. As demais colunas são derivadas automaticamente do *Faithfulness* RAGAS.

Tabela de avaliação — 3 modos (denso / esparsos / híbrido)

O detalhamento completo das respostas está em data/eval/rubrica_detalhada.md.

#	Pergunta (resumo)	Cat.	Acerto D/S/H	Faith. D / S / H	Correção	Recusa
Q1	Carga acidental em escritório (kN/m²)?	fact	<i>x</i> / <i>x</i> / <i>x</i>	0,00 / 1,00 / 1,00	N	N/A
Q2	Carga acidental garagem veículos leves?	fact	<i>x</i> / ✓ / ✓	0,00 / 1,00 / 1,00	S	N/A
Q3	Peso próprio = que tipo de carga?	fact	<i>x</i> / ✓ / ✓	0,50 / 1,00 / 0,67	S	N/A
Q4	Paredes divisórias sem posição — como tratar?	fact	<i>x</i> / ✓ / ✓	0,00 / 1,00 / 1,00	S	N/A
Q5	Peso específico do concreto armado?	fact	<i>x</i> / ✓ / ✓	0,00 / 1,00 / 1,00	S	N/A
Q6	Carga ao longo de parapeitos e balcões?	fact	<i>x</i> / <i>x</i> / <i>x</i>	1,00 / 0,75 / 1,00	S	N/A
Q7	Critérios de categoria	fact	<i>x</i> / ✓ / ✓	0,00 / 1,00 / 1,00	S	N/A

#	Pergunta (resumo)	Cat.	Acerto D/S/H	Faith. D / S / H	Correção	Recusa
	para garagens?					
Q8	Carga mínima em coberturas (manutenção)?	fact	<i>x</i> / ✓ / ✓	0,00 / 0,86 / 0,83	N	N/A
Q9	Quando reduzir cargas acidentais ?	fact	<i>x</i> / ✓ / ✓	0,00 / 1,00 / 1,00	S	N/A
Q10	Redução percentual — 6 ou mais pisos?	multi	<i>x</i> / ✓ / ✓	0,00 / 1,00 / 1,00	S	N/A
Q11	Definição da velocidade básica V0?	fact	✓ / ✓ / ✓	1,00 / 1,00 / 0,80	S	N/A
Q12	Pressão dinâmica do vento — definição e cálculo?	fact	<i>x</i> / ✓ / ✓	0,00 / 1,00 / 1,00	S	N/A
Q13	Três fatores S1, S2, S3 para calcular V _k ?	multi	<i>x</i> / ✓ / ✓	0,83 / 1,00 / 0,25	S	N/A
Q14	O que considera o fator	fact	<i>x</i> / ✓ / ✓	0,00 / 1,00 / 1,00	S	N/A

#	Pergunta (resumo)	Cat.	Acerto D/S/H	Faith. D / S / H	Correção	Recusa
	topográfico o S1?					
Q15	O que considera o fator S2?	fact	<i>x / ✓ / ✓</i>	N/D / 1,00 / N/D	S	N/A
Q16	Valor mínimo do fator S3 para residências?	fact	<i>x / ✓ / ✓</i>	0,00 / 0,67 / 0,67	S	N/A
Q21	Preço do m³ de concreto para obra em Brasília?	fora	— / — / —	0,00 / 0,00 / 0,00 ¹	—	S

¹ RAGAS ≈ 0 para recusas por limitação estrutural do método (ver nota acima). Q13 híbrido Faith.=0,25: resposta com baixo grounding — ver Exemplo 3.

Ganho do esparso/híbrido sobre o denso

Para evidenciar o ganho da Trilha A, a tabela abaixo cruza Acerto@5 dos três modos em questões representativas:

#	Pergunta (resumo)	Acerto D/S/H	Faith. Denso	Faith. Esparso	Faith. Híbrido
Q2	Carga garagem veículos leves	<i>x / ✓ / ✓</i>	0,00	1,00	1,00
Q3	Peso próprio = permanente ?	<i>x / ✓ / ✓</i>	0,50	1,00	0,67
Q5	Peso específico	<i>x / ✓ / ✓</i>	0,00	1,00	1,00

#	Pergunta (resumo)	Acerto D/S/H	Faith. Denso	Faith. Esparso	Faith. Híbrido
	concreto armado				
Q9	Redução cargas acidentais — quando?	x/✓/✓	0,00	1,00	1,00
Q11	Velocidade básica V0	✓/✓/✓	1,00	1,00	0,80
Q12	Pressão dinâmica do vento	x/✓/✓	0,00	1,00	1,00
Q14	Fator topográfico S1	x/✓/✓	0,00	1,00	1,00

Síntese: Os modos esparso e híbrido recuperam o *chunk* correto em 15–16 das 20 questões, contra apenas 1/20 do denso. O *Faithfulness* do esparso é $\approx 1,00$ na maioria dos casos, confirmando que, quando o *chunk* certo é recuperado, o LLM gera respostas bem fundamentadas. O híbrido tem *Faithfulness* igualmente alta, com exceção de Q13 (0,25), onde a resposta apresentou baixo *grounding*, ver Exemplo 3.

Exemplos notáveis

Exemplo 1 — Q11: resposta correta nos três modos

"Como é definida a velocidade básica do vento V0 pela NBR 6123?"

"A velocidade básica do vento, V0, é definida como a velocidade de uma rajada de 3 s, a 10 m acima do terreno, em campo aberto e plano, excedida em média uma vez em 50 anos [NBR6123, Seção 5.1]."

Faithfulness = 1,00. A definição reproduz fielmente o § 5.1 da NBR 6123:2023. Única questão onde o denso também acerta o nome do *chunk* (51_velocidade_básica_do_vento_v0) é semanticamente próximo da consulta.

Exemplo 2 — Q2: falha do denso, acerto do esparso

"Qual o valor de carga acidental para uma garagem de veículos leves?"

Denso (sem acerto): *"Não encontrei informação suficiente nas normas consultadas para responder esta pergunta."*

Esparso (acerto): *"[NBR6120, Seção 6.6.1] A carga acidental para garagem de veículos leves é dada pela Tabela 13 da NBR 6120. Considerando veículos leves, a Categoria I é a mais adequada, com as seguintes cargas: Carga uniformemente distribuída: 3 kN/m². Carga concentrada (Qk): 12 kN, atuando em uma região de 10 cm × 10 cm."*

Esse exemplo ilustra o ganho direto do BM25 sobre o denso: a consulta contém "garagem" e "veículos leves", termos que o BM25 associou exatamente ao *chunk*

[NBR6120#98_661_ações_em_garagens....](#) O BERTimbau não fez essa associação semanticamente.

Exemplo 3 — Q13: resposta parcial com risco de alucinação (denso)

"Quais são os três fatores que multiplicam V0 para obter a velocidade característica Vk?"

Denso (*Faithfulness* = 0,83): *"...S2 é confirmado como um dos fatores. S1 e S3 são mencionados implicitamente como necessários para calcular Vk, mas seus valores ou como são obtidos não estão detalhados na seção A.1 fornecida. (...) SOMENTE S2 é apresentado [NBR6123, Seção A.1 Fator S2]."*

O LLM menciona a fórmula $V_k = S1 \cdot S2 \cdot S3 \cdot V_0$ sem encontrá-la nos *chunks*, potencial alucinação parcial. O esparsos (acerto, *Faithfulness* = 1,00) recupera os *chunks* de S1, S2 e S3 e responde com precisão.

Exemplo 4 — Q21: recusa correta

"Como calcular o preço do m³ de concreto para uma obra em Brasília?"

"Não encontrei informação suficiente nas normas consultadas para responder esta pergunta. (A consulta está limitada a normas técnicas ABNT, e a pergunta envolve tema não normativo, especificamente relacionado a preços e orçamentos.)"

Recusa correta e bem justificada, o corpus cobre apenas normas de cargas e vento, não precificação. O LLM ainda acrescentou a razão da recusa, o que é um comportamento desejável de *grounding*.

6. Limitações e Próximos Passos

Limitações

Corpus limitado: O corpus cobre cargas permanentes, acidentais e forças de vento, mas deixa de fora normas importantes do projeto estrutural (NBR 6118 — concreto, NBR 7190 — madeira, NBR 8800 — aço). A NBR 6118 foi excluída por problemas de codificação no PDF disponível.

Segmentação sem sobreposição: Algumas respostas requerem informação distribuída entre o final de uma seção e o início de outra. Com sobreposição zero, o *retriever* pode não recuperar os dois *chunks* simultaneamente. Esse efeito é parcialmente mitigado pelo *retriever* híbrido ($k \times 3$ candidatos).

Seções muito grandes: A seção 6.2 (Cargas variáveis) da NBR 6120:2019 e algumas seções da NBR 6123 têm mais de 20.000 caracteres, acima do que modelos de *embedding* conseguem representar fielmente em um único vetor (limite típico: ~512 *tokens*). Em versões futuras, seria recomendável subdividir essas seções.

Fórmulas não decodificadas: O Docling converte fórmulas matemáticas para `<!-- formula-not-decoded -->` quando não consegue renderizá-las. Isso afeta algumas seções da NBR 6123 que contêm equações.

Dependência de API externa: A geração de respostas depende de APIs de LLM (Groq/Gemini). Para uso totalmente local, seria necessário integrar um modelo via `llama.cpp` ou Ollama.

Próximos Passos

Ampliação do corpus: Incluir a NBR 6118 (projeto de estruturas de concreto) quando um PDF com codificação correta estiver disponível, além de outras normas complementares como NBR 7190 (madeira) e NBR 8800 (aço). Isso permitiria ao sistema cobrir o ciclo completo de dimensionamento estrutural.

Subdivisão de seções extensas: Implementar uma etapa de pós-processamento que subdivida automaticamente seções com mais de ~4.000 caracteres, preservando os metadados da seção original. Isso melhoraria a representação vetorial no *retriever* denso e potencialmente elevaria o *recall* do modo híbrido.

Ajuste fino do modelo de *embeddings*: Realizar *fine-tuning* do BERTimbau (ou de um modelo *sentence-transformer*) no domínio normativo, utilizando pares pergunta–seção extraídos do *golden set* ampliado. O *recall* extremamente baixo do denso (0,05 em $k=3$) sugere que a representação semântica genérica é insuficiente para este vocabulário técnico.

Execução totalmente local: Integrar um modelo de geração local (ex.: Ollama com Llama 3) para eliminar a dependência de APIs externas, viabilizando o uso do sistema em ambientes sem acesso à internet ou com restrições de confidencialidade.

7. Referências

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. *NBR 6118: Projeto de estruturas de concreto - Procedimento*. Rio de Janeiro: ABNT, 2023.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. *NBR 6120: Cargas para o cálculo de estruturas de edificações*. 2. ed. Rio de Janeiro: ABNT, 2019.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. *NBR 6123: Forças devidas ao vento em edificações*. Rio de Janeiro: ABNT, 2023.

BROWN, Dorian. *rank-bm25: A collection of BM25 algorithms in Python*. GitHub. Disponível em: https://github.com/dorianbrown/rank_bm25. Acesso em: 3 abr. 2026.

ES, Shahul et al. *RAGAS documentation*. Disponível em: <https://docs.ragas.io>. Acesso em: 3 abr. 2026.

GRADIO. *Gradio documentation*. Disponível em: <https://www.gradio.app/docs>. Acesso em: 3 abr. 2026.

GROQ. *Groq API documentation*. Disponível em: <https://console.groq.com/docs>. Acesso em: 3 abr. 2026.

HUGGING FACE. *Transformers documentation*. Disponível em: <https://huggingface.co/docs/transformers>. Acesso em: 3 abr. 2026.

IBM RESEARCH. *Docling: document processing toolkit for generative AI pipelines*. GitHub, 2024. Disponível em: <https://github.com/DS4SD/docling>. Acesso em: 3 abr. 2026.

META AI. *FAISS: A library for efficient similarity search and clustering of dense vectors*. GitHub. Disponível em: <https://github.com/facebookresearch/faiss>. Acesso em: 3 abr. 2026.

TEIXEIRA, Israel Magalhães; BRAGA, Eduardo; CARVALHO, Marcelo. *pln-rag-normas-estruturais: Chatbot RAG para normas estruturais ABNT*. GitHub, 2026. Disponível em: <https://github.com/israelmteixeira1/pln-rag-normas-estruturais>. Acesso em: 3 abr. 2026.